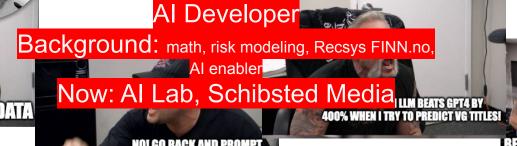
# Training and using LLMs in Schibsted

Simen Eide, Schibsted



# Training and using Ms in Schibsted

Simen Eide, Schibsted



# Schibsted is a text generation company



#### Kortversjonen

0

Oppsummeringen er laget av Al-verktøyet ChatGPT og kvalitetssikret av VGs journalister.

- Den avgåtte byrådslederen i Oslo, Raymond Johansen (Ap), fikk innvilget tre måneders etterlønn av eget byråd, få dager før han annonserte ny jobb som generalsekretær i Norsk Folkehjelp.
- Rødt er kritisk til hastebehandlingen, og at det var Johansens avtroppende byråd som innvilget etterlønn.
- Byrådslederens kontor vurderer nå å redusere Johansens etterlønn etter at han har kommet med nye opplysninger.
- Flere av Johansens byråder og politisk utnevnte byrådssekretærer har også fått innvilget inntil tre måneders etterlønn.

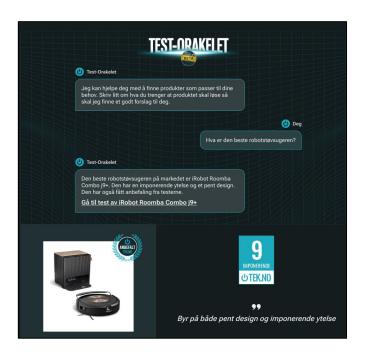
∧ Vis mindre

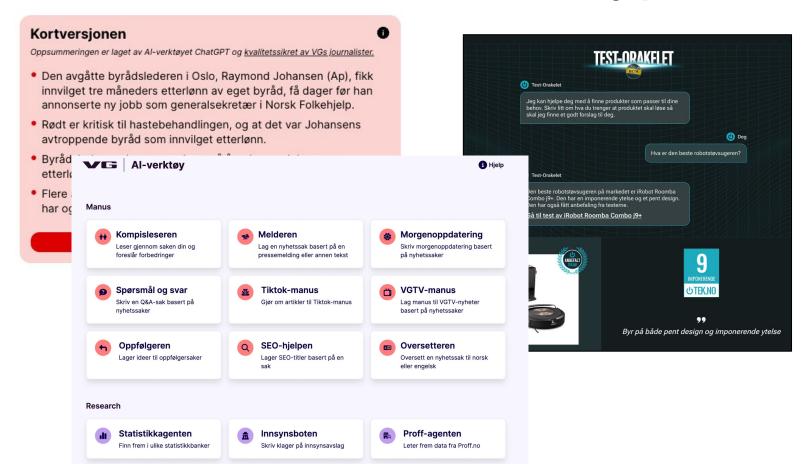
#### Kortversjonen

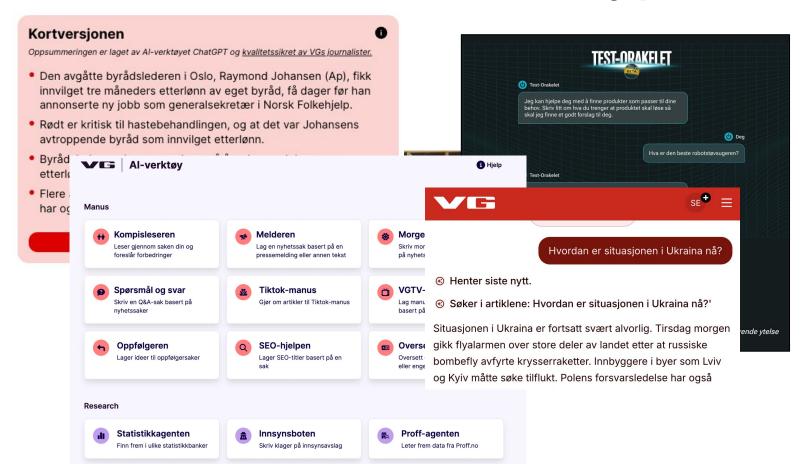
Oppsummeringen er laget av Al-verktøyet ChatGPT og kvalitetssikret av VGs journalister.

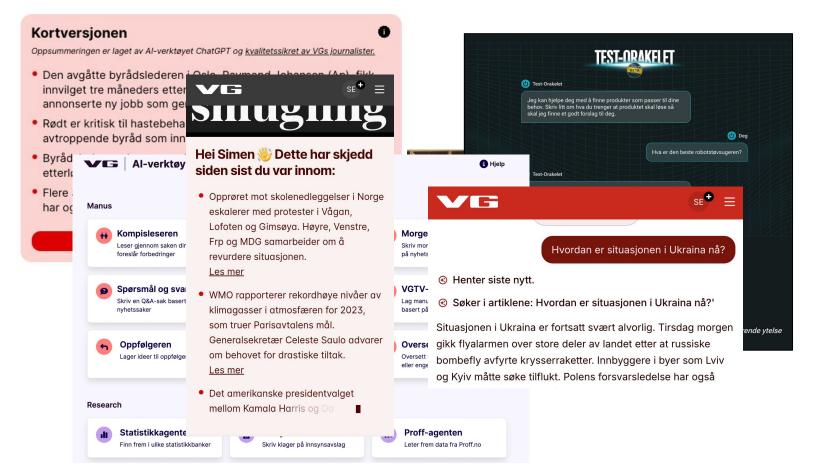
- Den avgåtte byrådslederen i Oslo, Raymond Johansen (Ap), fikk innvilget tre måneders etterlønn av eget byråd, få dager før han annonserte ny jobb som generalsekretær i Norsk Folkehjelp.
- Rødt er kritisk til hastebehandlingen, og at det var Johansens avtroppende byråd som innvilget etterlønn.
- Byrådslederens kontor vurderer nå å redusere Johansens etterlønn etter at han har kommet med nye opplysninger.
- Flere av Johansens byråder og politisk utnevnte byrådssekretærer har også fått innvilget inntil tre måneders etterlønn.

∧ Vis mindre

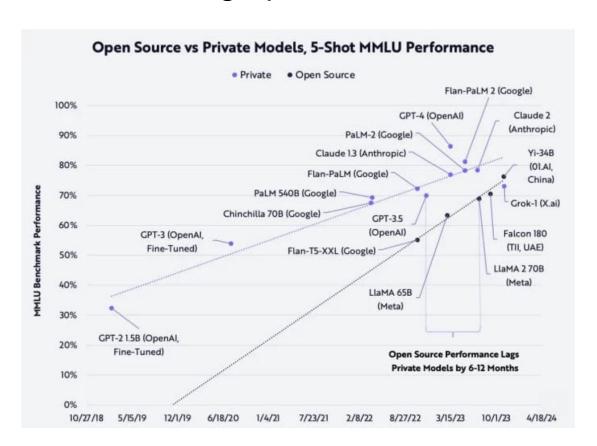








#### Open Source is catching up ... fast!

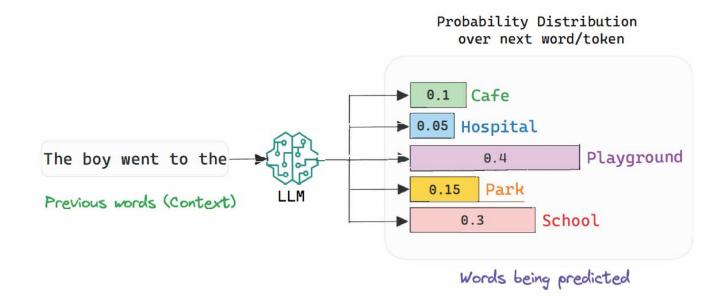


Enter:

Training your own language models

#### What are language models?

- Language models ONLY predict the next word in a text
- Learns through example: Text data



# What is finetuning?

Using LLMs does not change model

# What is finetuning?

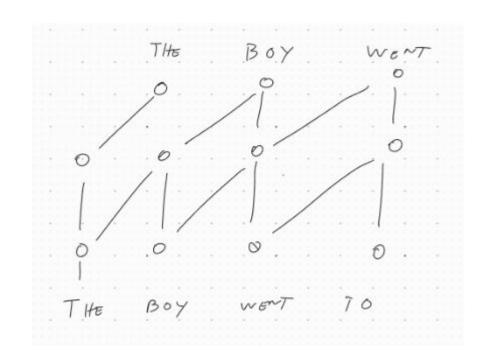
- Using LLMs does not change model
- Finetuning means we continue to learn the next word probabilities

#### What is finetuning?

- Using LLMs does not change model
- Finetuning means we continue to learn the next word probabilities
- Learning by example

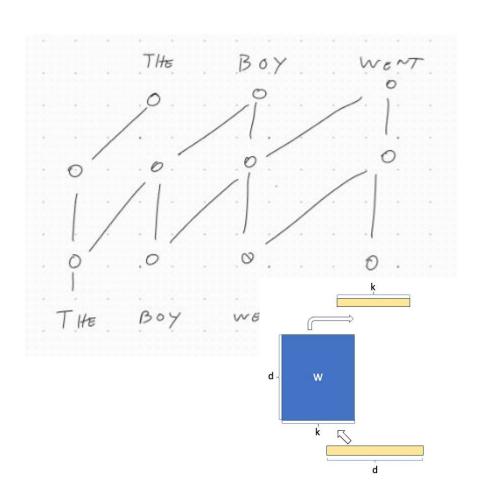


- Many layers of matrix multiplications



- Many layers of matrix multiplications
- Linear operation to find next layer

$$h_n=Wh_{n-1}$$

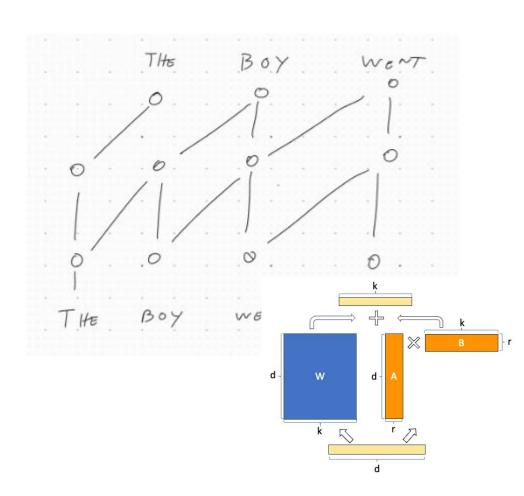


- Many layers of matrix multiplications
- Linear operation to find next layer

$$h_n = W h_{n-1}$$

 LoRA keeps the existing architecture + adds a dimension reduced layer to the architecture

$$h_n = Wh_{n-1} + ABh_n$$



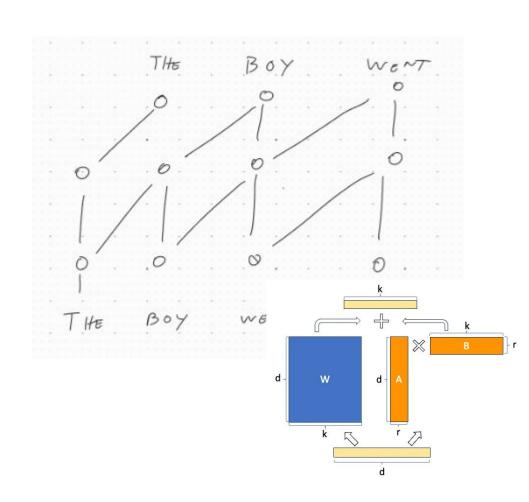
- Many layers of matrix multiplications
- Linear operation to find next layer

$$h_n = W h_{n-1}$$

 LoRA keeps the existing architecture + adds a dimension reduced layer to the architecture

$$h_n = Wh_{n-1} + ABh_n$$

- Result: Way less trainable parameters



- ChatGPT



- ChatGPT



- Business critical tasks
  - gpt4 titles "long, descriptive and American"

ChatGPT



- Business critical tasks
  - gpt4 titles "long, descriptive and American"



GPT-J from the National Library

NB-GPTJ 6B

ChatGPT



- Business critical tasks
  - gpt4 titles "long, descriptive and American"



GPT-J from the National Library

NB-GPTJ 6B

#### **Summer 2023:**

- Fine-tune on thousands of examples!











ChatGPT



- Business critical tasks
  - gpt4 titles "long, descriptive and American"



NB-GPTJ 6B



GPT-J from the National Library

**Summer 2023:** 

- Fine-tune on thousands of examples!

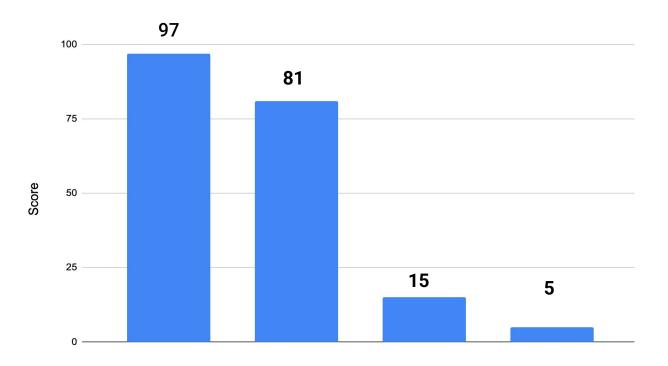


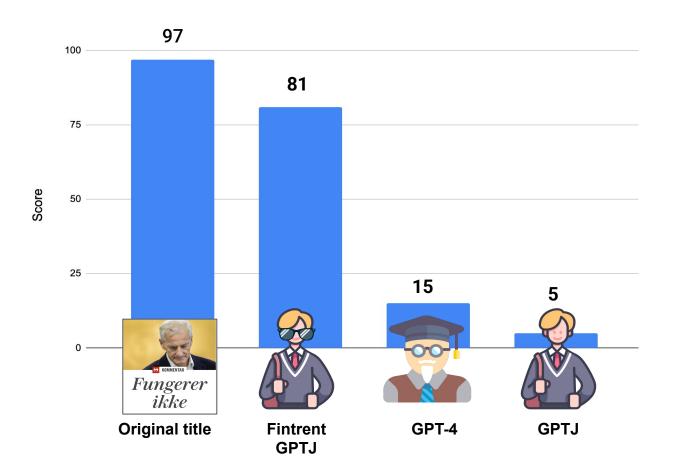


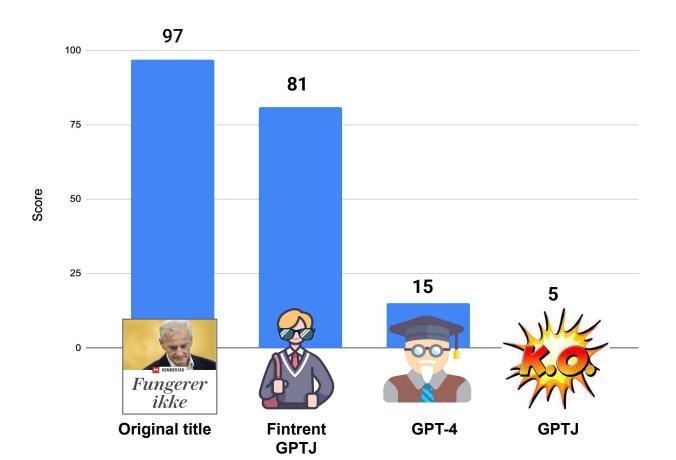


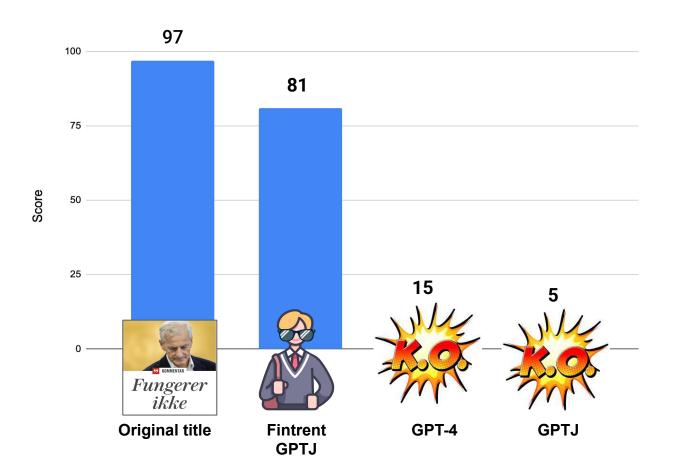


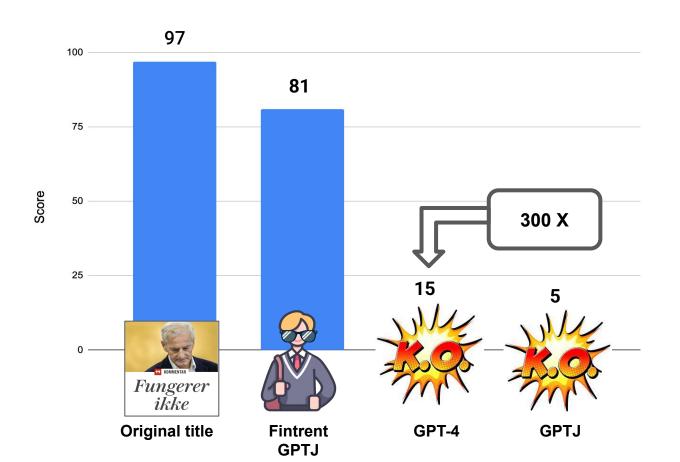












#### Better models => expand possibilities

# Klart for Northug-comeback i Finland

<u>Petter Northug</u> (37) har ikke gått et allround-renn på ski siden november 2018. Fredag står skikongen atter en gang på startstreken.

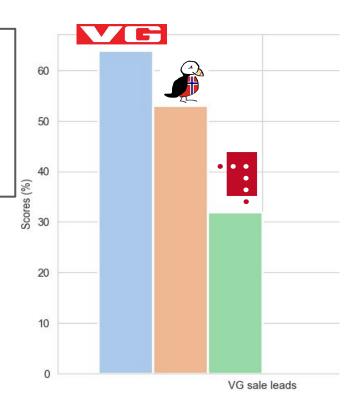
Suggestions (auto generated):

Petter Northug (37) skulle gjøre comeback i den finske langrennsåpningen, men det ble ingen start for ham.

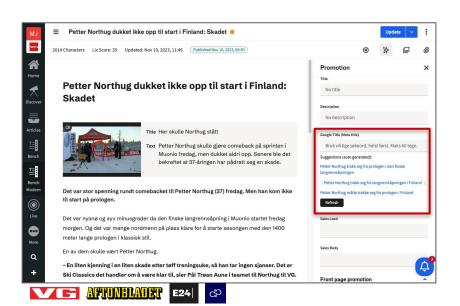
Petter Northug (37) satser langløp denne sesongen. Men det var en annen nordmann som var raskest i den finske langrennsåpningen.

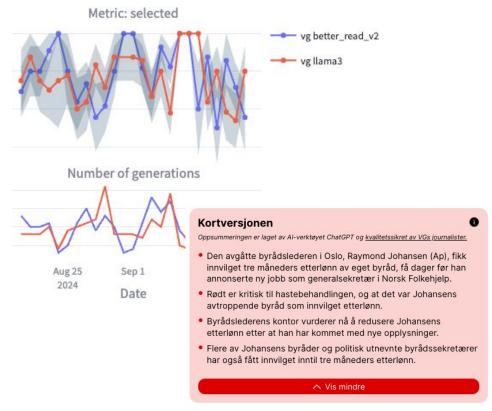
Petter Northug (37) var blant de ti løperne som trakk seg før start på den finske langrennsåpningen.

Refresh



# Integrate into our journalistic tools and A/B-test



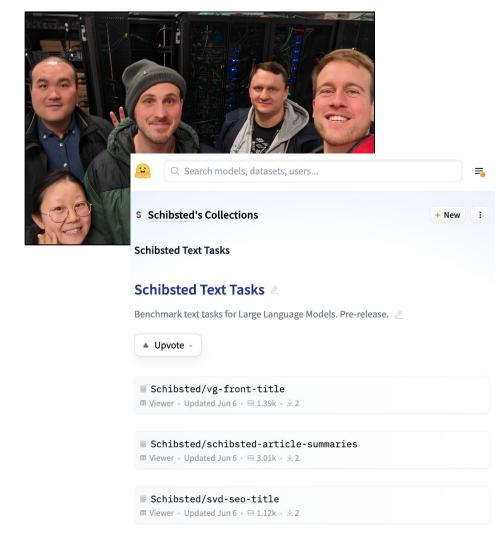


#### Research & data contributor

 Part of NorLLM project, member of Media Futures

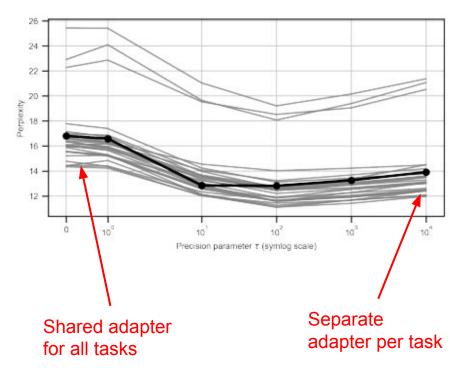
Contribute data to train LLMs

Contribute data to evaluation:
 Schibsted Text Tasks



#### How to share information across tasks?

- We have many similar but different tasks:
  - Front titles, seo titles, summaries, (...)
  - VG, Aftenposten, Svenske Dagbladet,
     (...)
- How can we best learn the features of each task?

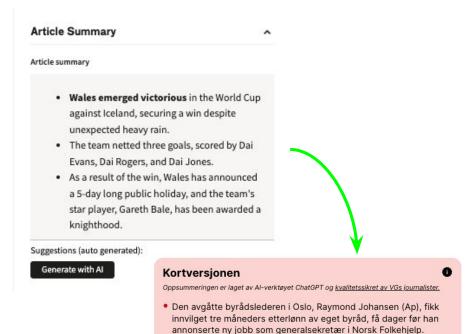


Preprint: Eide, Frigessi (2024): "BoRA: Bayesian Hierarchical Low-Rank Adaption for Multi-task Large Language Models"

#### Feedback loops

 We suggest a summary, the journalist edits it and we publish result.

- Few edits...
  - was it good?
  - journalist in a hurry?



Rødt er kritisk til hastebehandlingen, og at det var Johansens

Byrådslederens kontor vurderer nå å redusere Johansens etterlønn etter at han har kommet med nye opplysninger.
Flere av Johansens byråder og politisk utnevnte byrådssekretærer

har også fått innvilget inntil tre måneders etterlønn.

avtroppende byråd som innvilget etterlønn.

#### Can LLMs be shown directly to users?

- Strong principle of human-in-the-loop
- Limits personalized generations
- Are there areas where the risk is lower?





#### Hei Simen Dette har skjedd siden sist du var innom:

- Opprøret mot skolenedleggelser i Norge eskalerer med protester i Vågan, Lofoten og Gimsøya. Høyre, Venstre, Frp og MDG samarbeider om å revurdere situasjonen.
   Les mer
- WMO rapporterer rekordhøye nivåer av klimagasser i atmosfæren for 2023, som truer Parisavtalens mål.
   Generalsekretær Celeste Saulo advarer om behovet for drastiske tiltak.
- Det amerikanske presidentvalget mellom Kamala Harris og Do

Les mer



#### Who will train these open LLMs?

- Are universities able to keep up?
- Iteration cycle is fast
- NorLLM was launched 15 may based on llama2
  - Llama3 was launched 15 april
- Will the international models be good enough in Norwegian?



#### Future work



- Productify models
- Feedback loops (generate high performing titles)
  - Dpo, rlhf etc
- More and more complex use-cases
- User facing products: Large scale (responsible) feedback loops
- Multimodal: voice
- Recsys+RAG+ LLM = ?

#### Future work



- Productify models
- Feedback loops (generate high performing titles)
  - Dpo, rlhf etc
- More and more complex use-cases
- User facing products: Large scale (responsible) feedback loops
- Recsys+RAG+ LLM = ?

Do you have an idea that can be both a paper and a product?

Talk to me!
(@simeneide, simen.eide@schibsted.com)